پروژه پیش‌بینی مصرف برق لوازم خانگی
گزارش تحلیل اکتشافی داده و آماده‌سازی داده

تیم ۱ | تحویل تحلیل‌گر | مبتنی بر energydata_complete.csv (مخزن UCI ML شماره ۳۷۴)

منبع داده	energydata_complete.csv (Appliances Energy Prediction, UCI ID 374)
تعداد نمونه و ویژگی	19,735 سطر و 31 ستون
بازه زمانی	۲۰۱۶-۰۱-۱۱ تا ۲۰۱۶-۰۵-۲۷ (حدود ۴.۵ ماه، فاصله ۱۰ دقیقه‌ای)
متغیر هدف	Appliances (وات‌ساعت) — مصرف برق لوازم خانگی
مجوز	CC BY 4.0
فایل خروجی نهایی	appliances_energy_prepared.csv

۱. معرفی و مأموریت پروژه

است که خطای آن یک شرکت مدیریت انرژی ساختمان می‌خواهد بداند آیا داده‌های دما، رطوبت، شرایط بیرونی و الگوی زمانی این مصالحه را از نظر می‌توانند مصرف برق لوازم خانگی را در بازه‌های ده‌دقیقه‌ای برآورد کنند. هدف عملی، ساخت مدلی و هزینه نیز توجیه کند. در ساعات کم‌مصرف و پرمصرف به‌خوبی شناخته شده باشد و در عین حال با کاهش تعداد حسگرها، دقت

آیا می‌توان مصرف برق لوازم خانگی را با داده‌های در دسترس پیش‌بینی کرد و واقعا کدام حسگرها ارزش پیش‌بینی دارند؟ پرسش اصلی پروژه:

۲. توصیف دیتاست

منبع	UCI Machine Learning Repository, dataset #374
فایل خام	energydata_complete.csv
تعداد نمونه	19,735 رکورد با فاصله زمانی ۱۰ دقیقه
ویژگی/هدف	۲۸ ویژگی + ۱ متغیر هدف (Appliances، وات‌ساعت)
بازه جمع‌آوری	حدود ۴.۵ ماه
مقادیر گم‌شده اعلام‌شده	هیچ (صفر مقدار گم‌شده)
مجوز	CC BY 4.0

(lights) این دیتاست دمای داخلی (T1 تا T9) و رطوبت داخلی (RH_1 تا RH_9) در نه اتاق یک خانه کم‌مصرف، داده‌های می‌روند، هواشناسی بیرونی (T_out، RH_out، Press_mm_hg، Windspeed، Visibility، Tdewpoint)، مصرف انرژی روشنایی وجود دارد. و دو متغیر تصادفی تزریق‌شده (rv1، rv2) را که به‌عنوان معیار طبیعی برای سنجش کیفیت انتخاب ویژگی به‌کار ثبت کرده است. بررسی فایل نهایی نشان می‌دهد صفر مقدار گم‌شده و صفر سطر تکراری

نقش متغیرها (خلاصه فرهنگ داده)

ستون(ها)	نقش / توضیح
date	برچسب زمانی ثبت (با وضوح ۱۰ دقیقه)
Appliances	متغیر هدف — مصرف برق لوازم خانگی (وات‌ساعت)
lights	مصرف انرژی روشنایی (وات‌ساعت)
T1 تا T9 / RH_1 تا RH_9	دما (درجه سلسیوس) / رطوبت (درصد) هر اتاق
T_out, RH_out, Press_mm_hg, Windspeed, Visibility, Tdewpoint	قرائت‌های ایستگاه هواشناسی بیرونی
rv1, rv2	متغیرهای تصادفی (نویز) — بدون معنای فیزیکی، برای سنجش انتخاب ویژگی
hour, day_of_week	ویژگی‌های تقویمی مهندسی‌شده از ستون date

۳. کیفیت و یکپارچگی داده

• مقادیر گم‌شده: 0 مورد در دیتاست نهایی — یعنی هیچ.

• سطرهای تکراری: 0 مورد.

زمانی: دیتاست نهایی بر اساس تاریخ مرتب و کاملا صعودی است؛ غالب‌ترین فاصله نمونه‌برداری دقیقا ۱۰ دقیقه است.
• ترتیب

هیچ رطوبتی خارج از بازه [۰,۱۰۰]، و هیچ سرعت باد یا دید منفی مشاهده نشد — تمام بررسی‌ها موفق بود.
• بررسی محدوده فیزیکی: هیچ مقدار منفی در Appliances/lights،

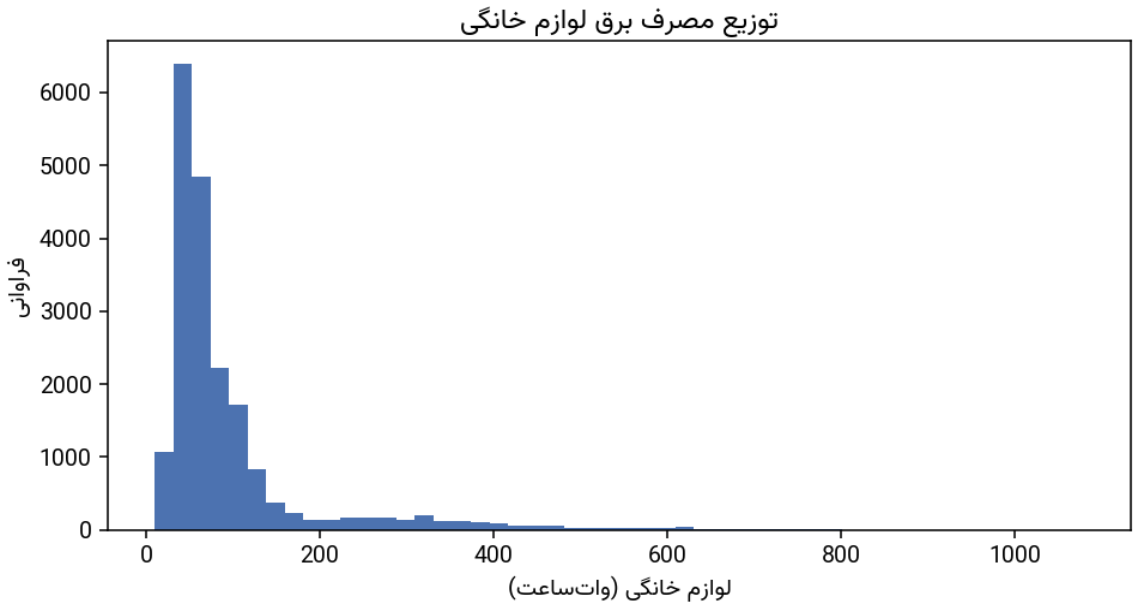
نیست؛ همبستگی rv1 و rv2 با هدف به‌ترتیب -0.011 و -0.011 است — یعنی عملا نویز، همان‌طور که انتظار می‌رفت.
• نشت مستقیم اطلاعات هدف: هیچ ویژگی با متغیر هدف (Appliances) یکسان

دارند (۱.۰۰=)، که با فرض نویز مصنوعی تزریق‌شده برای سنجش انتخاب ویژگی (و نه حسگرهای واقعی) هم‌خوانی دارد.
• نکته درباره rv1/rv2: در این نسخه آماده‌شده، دو ستون تصادفی با یکدیگر همبستگی کامل

۴. تحلیل آماری و توزیع

شاخص آماری	مقدار
میانگین	97.7 وات‌ساعت
میانه	60.0 وات‌ساعت
انحراف معیار	102.5 وات‌ساعت
کمینه / بیشینه	10 / 1080 وات‌ساعت
صدک ۷۵ / ۹۰	100 / 196 وات‌ساعت
صدک ۹۵ / ۹۹	330 / 577 وات‌ساعت

پرمصرف است. ۷۵٪ قرائت‌ها توزیع متغیر هدف به‌شدت چوله به راست است: میانگین (97.7 وات‌ساعت) به‌وضوح بالاتر از درحالی‌که بیشینه به 1080 وات‌ساعت می‌رسد — حدود 18 میانه (60 وات‌ساعت) قرار دارد که ناشی از دنباله بلند رویدادهای پیامد مستقیمی برای مدل‌سازی دارد: مدلی که صرفا برای خطای میانگین (RMSE) بهینه شده ۱۰۰ وات‌ساعت یا کمتر هستند، دقیق به نظر برسد اما در پیش‌بینی دوره‌های نادر پرمصرف که از نظر عملیاتی اهمیت بیشتری دارند، برابر میانه. این موضوع ضعیف عمل کند. می‌تواند در ظاهر



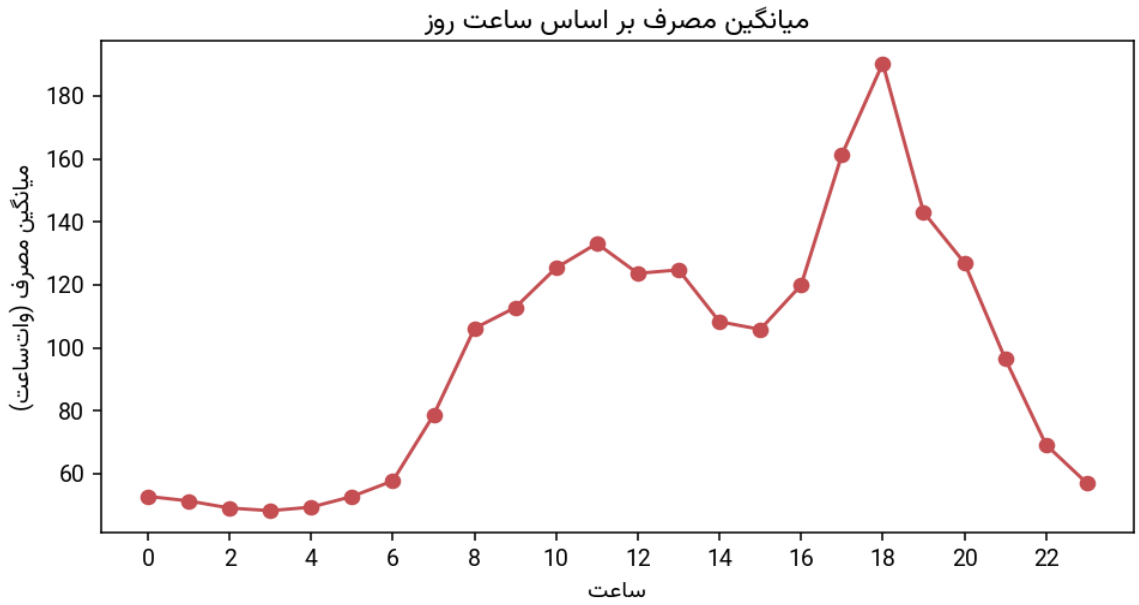
نمودار ۱ — توزیع مصرف برق لوازم خانگی (چولگی به راست، دنباله بلند به‌سوی مصرف بالا)



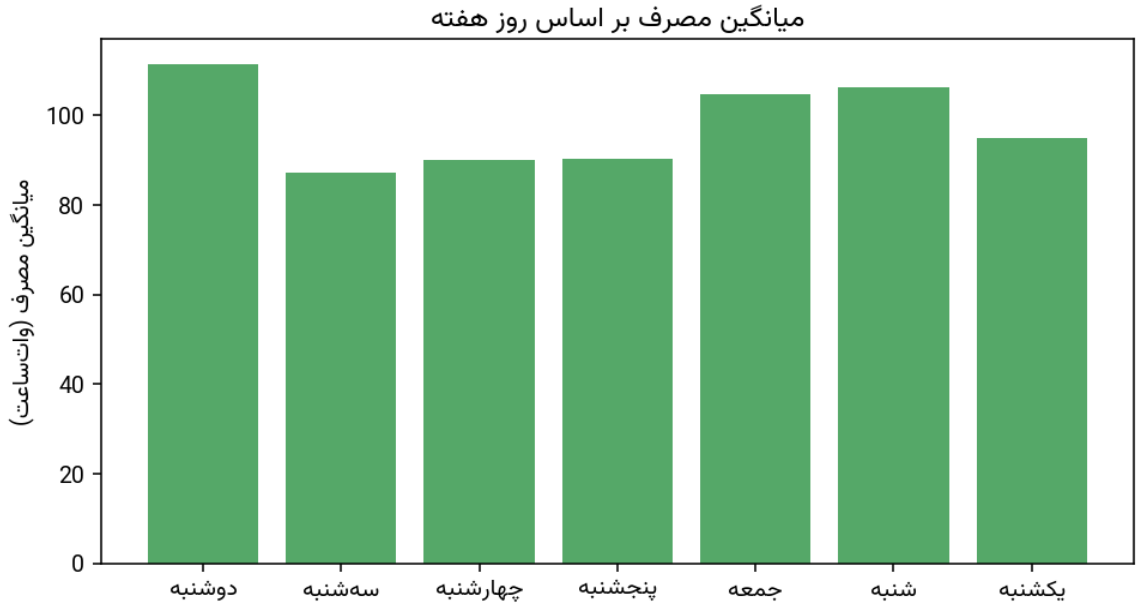
نمودار ۲ — نمودار جعبه‌ای Appliances (وات‌ساعت)، نشان‌دهنده خوشه متراکم کم‌مصرف و نقاط پرت پرمصرف مکرر

۵. الگوهای زمانی مصرف

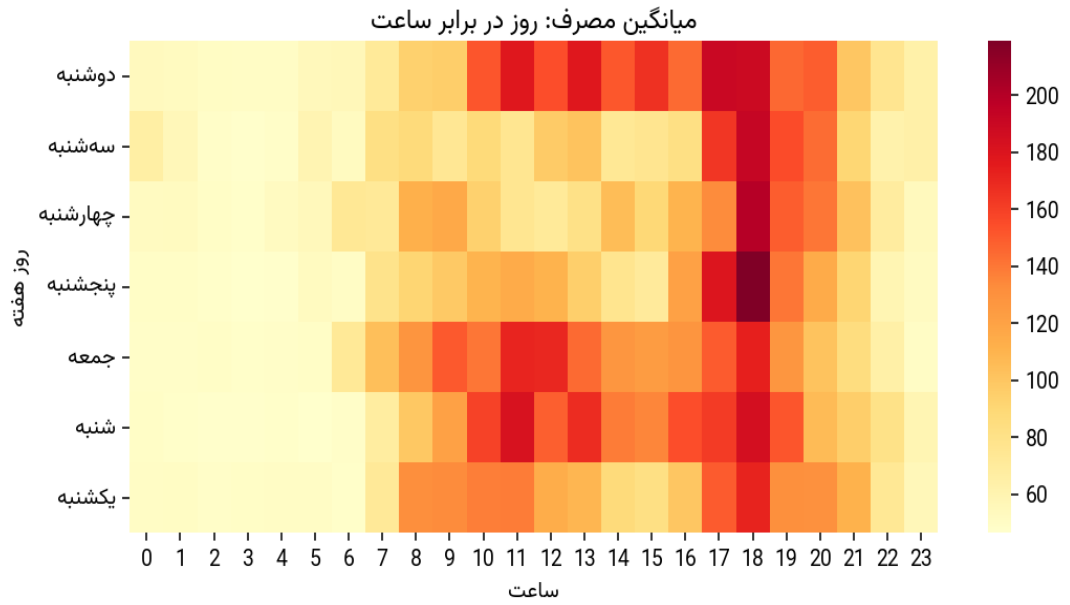
درحالی‌که کم‌مصرف‌ترین دوره حدود مصرف از یک ریتم روزانه مشخص پیروی می‌کند. پیک مصرف در ساعت 18:۰۰ رخ می‌دهد (48 وات‌ساعت) که با ساعات خواب شبانه مطابقت دارد. (میانگین 190 وات‌ساعت) که با فعالیت عصرگاهی هم‌خوانی دارد، شبیه به تفاوت روزهای هفته. در سطح هفتگی، دوشنبه بالاترین میانگین مصرف را دارد (111 وات‌ساعت) و ساعت 3:۰۰ است سه‌شنبه کمترین را (87 وات‌ساعت) — یک اثر ملایم اما پایدار



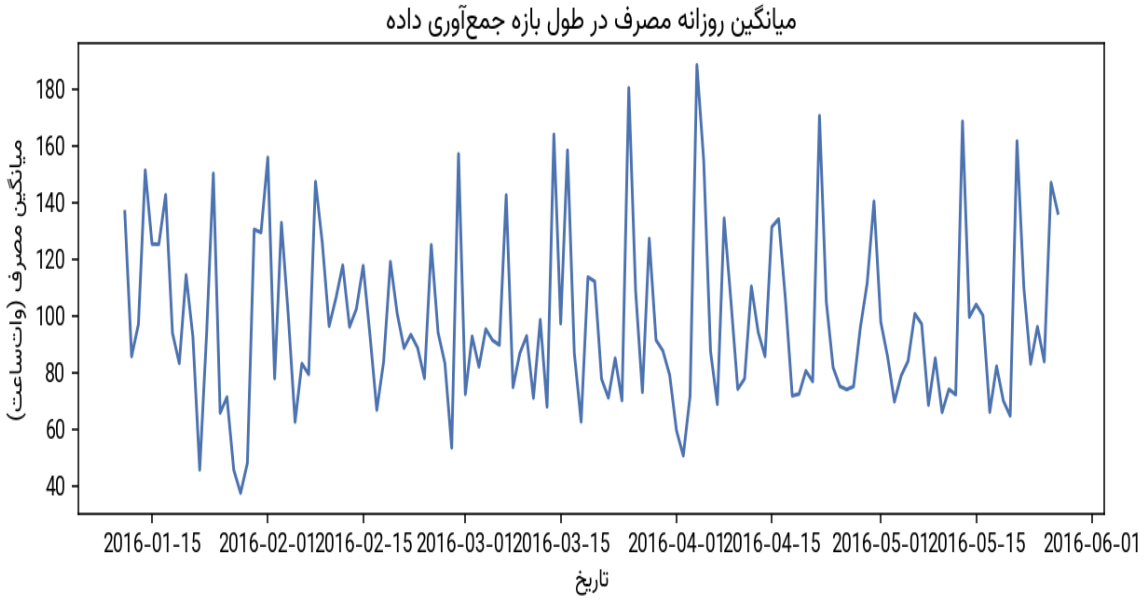
نمودار ۳ — میانگین مصرف بر اساس ساعت روز



نمودار ۴ — میانگین مصرف بر اساس روز هفته



نمودار ۵ — نقشه حرارتی روز × ساعت: ساعات عصر در اکثر روزها غالب است

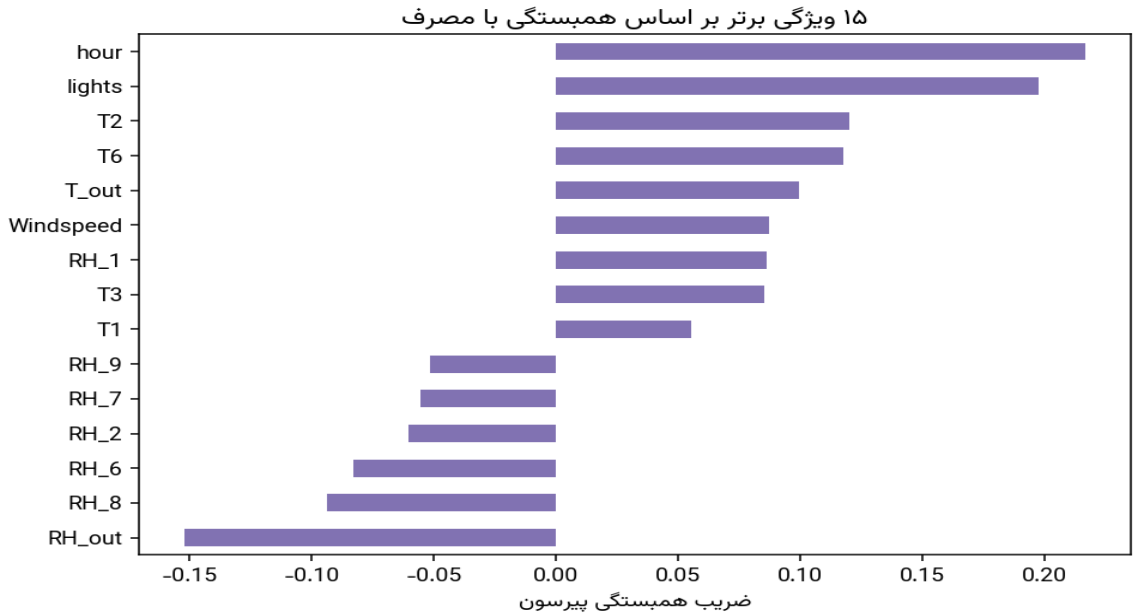


نمودار ۶ — میانگین روزانه مصرف در طول بازه حدودا ۴.۵ ماهه جمع‌آوری داده

۶. رابطه ویژگی‌ها با متغیر هدف

ویژگی	همبستگی با Appliances
hour	+0.217
lights	+0.197
RH_out	-0.152
T2	+0.120
T6	+0.118

و چند دمای تمام همبستگی‌های خطی با متغیر هدف ضعیف هستند (کمتر از ۰.۲۲ در قدر مطلق) — قوی‌ترین آن‌ها ویژگی بیشتر غیرخطی و رفتاری مهندسی‌شده hour، سپس lights (هم‌زمانی استفاده از لوازم و روشنایی)، رطوبت بیرونی (منفی) همین موضوع الزام سند پروژه برای داخلی/بیرونی است. این نشان می‌دهد رابطه بین قرائت‌های حسگر و مصرف لوازم خانگی صرفا گزارش همبستگی به‌عنوان رابطه علی. (ناشی از حضور افراد در خانه) است تا یک تابع فیزیکی مستقیم از دما/رطوبت — مقایسه یک مدل غیرخطی با خط پایه را توجیه می‌کند، نه



نمودار ۷ — ۱۵ ویژگی برتر بر اساس قدر مطلق همبستگی با Appliances

مرحله انتخاب حسگرهای دما/رطوبت داخلی در اتاق‌های مختلف همبستگی قوی با یکدیگر دارند (محیط حرارتی مشترک خانه)، ارزش‌افزوده دارد. یعنی بسیاری از ۲۶ ویژگی خام حسگر، اطلاعات تکراری حمل می‌کنند — این موضوع یکی از دلایل اصلی برای ویژگی با الگوریتم ژنتیک در این پروژه است، نه فرض اینکه هر حسگر مستقل

۷. تحلیل نویز و نقاط پرت

می‌گیرند. بر اساس سند پروژه، این مقادیر به‌عنوان با استفاده از قاعده استاندارد ۱.۵×IQR، 10.8٪ از قرائت‌های Appliances در نظر گرفته می‌شوند — هیچ سطری صرفا به این دلیل حذف نشده (بالاتر از 175 وات‌ساعت) خارج از محدوده آماری قرار نقاط پرت به‌تفکیک ستون: lights (22.7٪)، مصرف دوحالتی روشن/خاموش)، رویدادهای واقعی پرمصرف، نه خطای اندازه‌گیری

الگوی خرابی حسگر (قرائت ثابت، بازه غیرممکن) ندارد؛ Visibility (12.8٪)، خود Appliances (10.8٪) و است. بیشترین سهم مدل‌سازی موکول می‌شود (تابع هزینه مقاوم / وینزورایز فقط بر اساس داده‌های آموزش). RH_5 (6.7٪). هیچ ستونی نشانه تصمیم‌گیری نهایی به مرحله

۸. آمادگی برای مدل‌سازی و یادداشت‌های تحویل

اما مقادیر تأخیری/آینده حسگرها فقط در صورتی مجازند که درون یک Pipeline مبتنی بر داده آموزش ساخته شوند.
زمانی ورودی‌ها — هیچ اطلاعات آینده نباید وارد مدل شود؛ ویژگی‌های تقویمی (hour، day_of_week) مجاز هستند
• هدف و افق پیش‌بینی: پیش‌بینی Appliances در همان برچسب

پایانی به‌عنوان Test)، نه یک جداسازی تصادفی، تا ماهیت سری‌زمانی داده و جلوگیری از نشت بین Foldها رعایت شود.
• تقسیم آموزش/آزمون: باید کاملا زمانی باشد (حدود ۲۰٪

تیم باید پیش از قضاوت در مورد ارزش‌افزوده یک مدل غیرخطی، یک مرجع ساده (مثل میانگین متحرک/فصلی) تعیین کند.
• خط پایه:

مرحله انتخاب ویژگی نگه داشته شده‌اند — یک روش انتخاب ویژگی قابل‌اعتماد باید اهمیت ناچیزی به آن‌ها اختصاص دهد.
• متغیرهای تصادفی rv1/rv2: به‌طور خاص برای راستی‌آزمایی

روز و رژیم مصرف (عادی در برابر پیک) تفکیک شود تا یک امتیاز میانگین خوب، عملکرد ضعیف در زمان پیک را پنهان نکند.
RMSE/MAE/R² باید برای Train، Validation و Test به‌صورت جدا گزارش شوند؛ همچنین خطا باید به‌تفکیک ساعت
• ارزیابی: معیارهای

مهندسی‌شده hour و day_of_week؛ آماده برای تحویل به معمار جهت انتخاب مدل و انتخاب ویژگی با الگوریتم ژنتیک.
appliances_energy_prepared.csv — صفر مقدار گم‌شده، صفر رکورد تکراری، مرتب‌شده بر اساس تاریخ، با ویژگی‌های
• دیتاست نهایی:

۹. نتیجه‌گیری

به راست و دیتاست تمیز است (بدون مقدار گم‌شده، بدون رکورد تکراری، با فاصله ثابت ۱۰ دقیقه‌ای) و با اعمال تقسیم زمانی (پیک دوشنبه) پیروی مناسب و مهندسی ویژگی، برای وظیفه پیش‌بینی این پروژه کاملا مناسب است. مصرف لوازم خانگی چوله به‌خوبی توضیح‌پذیر باشد (بیشینه |0.22 ≈ |). وابسته به حضور افراد است و از ریتم‌های روزانه (پیک ساعت ۱۸:۰۰) و هفتگی غیرخطی و مرحله انتخاب ویژگی مبتنی بر الگوریتم ژنتیک — با استفاده از می‌کند، نه آنکه با یک حسگر دما یا آب‌وهوایی واحد به‌عنوان راستی‌آزمایی داخلی — به‌جای تکیه بر یک خط پایه خطی ساده حمایت می‌کنند. این یافته‌ها از انتخاب یک خانواده مدل rv1/rv2