گزارش فنی پروژه

گزارش فنی و حرفه‌ای پروژه

پیش‌بینی مصرف برق لوازم خانگی با طراحی Pipeline زمانی، انتخاب ویژگی ژنتیکی و ارزیابی چندمعیاره

عنوان پروژه	Architecture — Appliances Energy Prediction
متغیر هدف	Appliances
نوع مسئله	مسئله رگرسیون روی داده‌های سری زمانی
وضعیت سند	گزارش معماری و منطق پیاده‌سازی؛ اجرای عددی نیازمند CSV واقعی است

۱. خلاصه مدیریتی

این پروژه یک معماری قابل دفاع برای پیش‌بینی مصرف برق لوازم خانگی ارائه می‌کند. طراحی بر پایه ماهیت زمانی داده، جلوگیری از نشت اطلاعات، مقایسه مدل‌های خطی و غیرخطی، انتخاب ویژگی با الگوریتم ژنتیک و ارزیابی جداگانه رفتار عادی و Peak انجام شده است.

۲. تعریف مسئله و دامنه

متغیر هدف پروژه **Appliances** است و مسئله در دسته رگرسیون قرار می‌گیرد؛ بنابراین مدل باید مقدار پیوسته مصرف را پیش‌بینی کند. به دلیل ماهیت زمانی داده، ترتیب رخدادها و جداسازی گذشته از آینده در طراحی آزمایش اهمیت حیاتی دارد.

- طراحی Pipeline انتهابه‌انتها برای اعتبارسنجی، مهندسی ویژگی، آموزش و ارزیابی.
- کاهش ریسک Data Leakage در پیش‌پردازش و انتخاب ویژگی.
- مقایسه منصفانه چند خانواده مدل.
- اندازه‌گیری عملکرد کلی و عملکرد مدل در شرایط پرمصرف.

۳. شناخت داده و اعتبارسنجی اولیه

دیتاست مورد انتظار شامل ۱۹،۷۳۵ رکورد و ۳۱ ستون است و فایل ورودی با نام `csv.prepared_energy_appliances` خوانده

می‌شود. در ورودی تحویل‌شده فایل CSV واقعی وجود ندارد و Notebook نیز اجرا نشده است؛ بنابراین این گزارش منطق معماری و پیاده‌سازی را مستند می‌کند و ادعای اعداد عملکرد نهایی ندارد.

کنترل‌های کیفیت داده

- بررسی وجود ستون هدف و توقف در صورت نبودن **Appliances**.
- محاسبه مجموع مقادیر گمشده و شمارش ردیف‌های تکراری.
- تبدیل date به datetime و شمارش تاریخ‌های نامعتبر.
- مرتب‌سازی داده بر اساس زمان پیش از Split.

۴. مهندسی ویژگی

از ستون **date** دو ویژگی زمانی شامل **hour** و **day_of_week** ساخته می‌شود. timestamp خام مستقیماً وارد مدل نمی‌شود تا مدل از مؤلفه‌های زمانی قابل‌تفسیر استفاده کند.

- عدم استفاده از ویژگی‌های آینده یا Lag نامطمئن.
- Fit کردن Imputer و Scaler فقط روی Train.
- نگه‌داشتن **rv1** و **rv2** برای سنجش حذف ویژگی‌های کم‌ارزش.

۵. طرح تقسیم داده

تقسیم پیشنهادی به‌صورت ترتیبی انجام می‌شود: حدود ۷۰٪ ابتدایی برای Train، حدود ۱۰٪ بعدی برای Validation و ۲۰٪ پایانی برای Test. این انتخاب معادل سناریوی واقعی پیش‌بینی آینده است.

۶. Baseline و معیارهای ارزیابی

Baseline برابر میانگین مقدار هدف در Train تعریف می‌شود. معیارهای اصلی شامل **MAE**، **R^2** و **RMSE** هستند؛ همچنین **MAE Peak** روی ۱۰٪ بالایی مقادیر مصرف محاسبه می‌شود.

۷. مدل‌های بررسی‌شده

چهار مدل **Linear Regression**، **Ridge**، **Random Forest** و **Gradient Boosting** در دو خانواده خطی و غیرخطی مقایسه می‌شوند. پیش‌پردازش در Pipeline انجام می‌شود تا ریسک نشت اطلاعات کاهش یابد.

۸. انتخاب ویژگی با الگوریتم ژنتیک

هر کروموزوم یک بردار دودویی است که انتخاب یا حذف هر ویژگی را مشخص می‌کند. تابع Fitness برابر **R^2** اعتبارسنجی منهای جریمه تعداد ویژگی‌هاست؛ بنابراین الگوریتم میان دقت و سادگی مصالحه ایجاد می‌کند.

- جمعیت اولیه تصادفی از ماسک‌های ویژگی.
- انتخاب Tournament، Crossover تک‌نقطه‌ای و Mutation.
- Elitism برای حفظ جواب‌های برتر.
- تضمین انتخاب حداقل یک ویژگی.

۹. منطق انتخاب مدل نهایی

پس از استخراج زیرمجموعه ویژگی‌ها، مدل‌ها با ویژگی‌های منتخب دوباره ارزیابی می‌شوند. رتبه‌بندی اصلی بر اساس **R^2** است و **RMSE** و **MAE Peak** به‌عنوان معیارهای ثانویه در تصمیم مهندسی لحاظ می‌شوند.

۱۰. آموزش نهایی و آزمون مستقل

پس از انتخاب مدل، Train و Validation ادغام می‌شوند. مدل نهایی با ویژگی‌های منتخب آموزش داده می‌شود و فقط یک‌بار روی Test ارزیابی می‌شود.

۱۱. تحلیل خطا و رفتار Peak

خطای پیش‌بینی در دو رژیم **Normal** و **Peak** بررسی می‌شود. برای هر رژیم تعداد نمونه، **RMSE**، **MAE** و میانگین مقدار واقعی در برابر میانگین پیش‌بینی گزارش خواهد شد.

۱۲. خروجی‌های مورد انتظار

خروجی‌ها شامل جدول مقایسه مدل‌ها، فهرست ویژگی‌های منتخب، نتایج نهایی Test، نمودار پیشرفت الگوریتم ژنتیک، نمودار **Actual** در برابر **Predicted** و خلاصه خطای Normal و Peak هستند.

۱۳. نقاط قوت معماری

رعایت ماهیت زمانی داده، تفکیک روشن Train/Validation/Test، وجود Baseline، استفاده از معیار Peak، انتخاب ویژگی با تابع هدف مشخص و استفاده از Pipeline از نقاط قوت اصلی این معماری هستند.

۱۴. محدودیت‌ها و پیشنهادهای بهبود

برای تکمیل نتایج عددی باید CSV واقعی اجرا شود. همچنین ارزیابی **Walk-Forward**، تنظیم ابرپارامترها، ویژگی‌های **Lag** و **Rolling** با کنترل دقیق نشت اطلاعات، و بررسی هزینه کم‌برآوردی در Peak پیشنهاد می‌شود.

Notebook بدون CSV واقعی و خروجی اجرای سلول‌ها تحویل شده است؛ بنابراین اعداد عملکرد هنوز قابل درج نیستند.

تنها یک تقسیم زمانی استفاده شده و ارزیابی چندپنجره‌ای می‌تواند پایداری را بهتر نشان دهد. ویژگی‌های Rolling و Lag نیز مشروط به کنترل دقیق نشت اطلاعات می‌توانند ارزشمند باشند.

۱۵. جمع‌بندی نهایی

این معماری یک چارچوب منظم و قابل دفاع برای پیش‌بینی مصرف برق لوازم خانگی فراهم می‌کند. رعایت ترتیب زمانی، محدود کردن مشاهده Test به مرحله نهایی و کنترل نشت اطلاعات از مهم‌ترین تصمیم‌های طراحی هستند.

وضعیت تحویل

نسخه اصلاح‌شده باید با پشتیبانی درست از راست‌به‌چپ و نمایش صحیح متن فارسی ارائه شود.